

Segmentación y clasificación de salubridad en hojas de plantas de café

Mendoza, Agustín

Resumen—La detección y segmentación de hojas es un problema complejo para el procesamiento de imágenes. Estas, en su ambiente natural se encuentran superpuestas o en grupos, por lo que delimitar sus bordes no es una tarea sencilla debido a la similitud de sus colores y texturas con las de su fondo. En este trabajo se propone un método de segmentación y clasificación automático en un proceso de eliminación de fondo y separación de hojas.

Palabras clave—Segmentación, Morfología matemática, Detección de bordes, Máscara binaria, Intersection over Union.

I. INTRODUCCIÓN

Se estima que unas 125 millones de personas viven del cultivo de café, con una producción superior a los 100 millones de sacos anuales. Solo en América Latina se produce mas de la mitad del café mundial, con Brasil como su máximo exponente con mas de 2 millones de hectáreas plantadas[1].

La principal manera de maximizar la producción es mantener las plantas en estado saludable, por lo que un temprano y eficiente diagnóstico de enfermedades es una cuestión fundamental para los productores.

Un diagnóstico inicial puede realizarse mediante la observación de las hojas, distintas enfermedades y plagas generan patrones en su coloración y textura. La identificación de los mismos puede ayudar como un llamado de atención hacia la planta para un posterior control por parte de los botánicos. Con la intención de reducir tiempo, y por ende costos de producción, se elaboró esta propuesta de detección e identificación automática mediante fotografías. La misma cuenta con tres ejes fundamentales: eliminación del fondo, separación e identificación de hoja principal y clasificación de salubridad.

Este modelo fue entrenado y probado con la base de datos RoCoLe[2] que se compone de fotografías a color de hojas de plantas de café en su estado natural.

II. MODELO DE SEGMENTACIÓN Y CLASIFICACIÓN

El modelo de segmentación y clasificación sigue una secuencia de dos procesos centrales (Fig.1) que se efectúan sobre la imagen de entrada. Como primer proceso se tiene la segmentación de la hoja principal, que a su vez se divide en tres tareas esenciales: enmascarado de suelo, eliminación de fondo y separación de hojas. En donde en el primero se trata de eliminar secciones de suelo, el cual cuenta con demasiados bordes, además de ruidos en similitud a las hojas, lo que optimiza el procesamiento en la detección de

bordes en las secciones de hojas. A partir de esto, en el segundo, se eliminan texturas y se realzan bordes. Con estos datos se generan contornos y se extrae el representativo a la hoja principal, generando una máscara de la misma. En segundo proceso, está la clasificación binaria sobre la hoja principal, realizada con la imagen en HSV -a fin de evitar que el brillo o la luz interfieran en la segmentación- por medio de Tono y Saturación se extraen defectos en la misma y se analiza el porcentaje del área afectada.

Para ambos procesos fueron utilizadas imágenes de entrenamiento seleccionadas al azar para realizar el ajuste de parámetros. Terminada la etapa de entrenamiento se seleccionó otro conjunto con imágenes diferentes al azar para realizar las pruebas.

A continuación se hará una descripción detallada de cada uno de los pasos que se siguieron para el desarrollo de este modelo.




Fig.1 Diagrama de bloques del proceso de segmentación y clasificación

A. Escalado de la imagen

Se utiliza la imagen color en formato RGB de entrada y se le realiza un reajuste de tamaño llevándola a una resolución de 614x346 píxeles, que en la mayoría de los casos corresponde a una escala del 30% de la imagen original. La interpolación realizada en este proceso permite una mayor amplitud en los parámetros de segmentación.

B. Enmascarado del suelo

En esta etapa se procesó la imagen reescalada, realizando una transformación de formato RGB a HSV para realizar una segmentación por Tono y Saturación, y evitar efectos adversos con el brillo en la misma. Se utilizaron distintas variaciones de parámetros: eliminando las secciones de suelo o eliminando las secciones de planta e invirtiendo la máscara. Los mismos fueron estipulados por prueba y error, generando una máscara binaria con mejores resultados en la eliminación del suelo.

1) *Optimización de máscara suelo:* A partir de la imagen binaria obtenida, se realizó una optimización de la misma con el fin de eliminar ruido y bordes espurios. La misma fue realizada mediante morfología matemática con operaciones de cierre y un elemento estructurante circular. Se utilizaron distintos tamaños del mismo, desde 3x3 hasta 11x11, teniendo mejores resultados cualitativos con un tamaño de 9x9 y 10 iteraciones.

C. Extracción del fondo

Para esta etapa se realizó el enmascarado entre la imagen y la máscara obtenida en el proceso anterior.

1) *Generación de región de interés:* A partir de esta imagen se generó una en escala de grises para luego realizar una detección de bordes. Se probó con los operadores de Canny y Laplaciano, realizando variaciones de parámetros por prueba y error; teniendo mejores resultados cualitativos en el último. A este resultado se le realizó una operación de dilatación con un elemento circular de 5x5 para engrosar los bordes y luego una operación de cierre para encapsular las secciones de suelo restante.

A continuación se invierte esta imagen para quedarnos con la máscara perteneciente a la región de hojas, que mediante de operaciones de dilatación y erosión se optimiza dicha superficie.

2) *Selección región principal:* El proceso anterior da como resultado una máscara binaria donde se encuentra el área que encierra a la hoja principal y áreas secundarias pertenecientes a suelo y hojas vecinas.

El objetivo de este paso es aislar el área que contiene el objetivo, para esto, mediante componentes conectadas buscamos el área máxima en la imagen de entrada y realizamos operaciones de cierre (Fig.2).




Fig.2 Imagen de entrada y salida al proceso, respectivamente

D. Separación de hojas

Este proceso tiene como objetivo delimitar los contornos del conjunto de hojas en la que se encuentra la hoja principal. La entrada al mismo es la imagen enmascarada del proceso anterior, es decir, sin el suelo u otro fondo que no sean hojas. [3]

1) *Eliminación de texturas y realce de bordes:* Se utilizó un filtro de suavizado con preservación de bordes[4] para difuminar el interior de las hojas. A este resultado se le aplicó un procesamiento de "acuarelado" abstrayendo

regiones de bajo contraste y preservando o mejorando las características de alto contraste, lo que elimina las texturas propia de la hoja y realza sus bordes. Los parámetros fueron establecidos por medio de prueba y error.

2) *Generación de contornos:* En esta etapa, utilizando la salida anterior en escala de grises. Se le aplica un filtro gaussiano de 5x5 y sigma 0.5 para suavizar el fondo, seguido de un filtro promediado de 5x5 para terminar de eliminar bordes internos a las hojas. Luego se umbraliza la imagen mediante una binarización adaptativa gaussiana y se buscan los contornos exteriores, resultando en una delimitación de regiones: hoja principal y fondo. (Fig.3)



Fig.3 Imagen de generación de contornos

3) *Selección de hoja principal:* La generación de contornos junto con una operación lógica OR en la máscara del proceso de extracción del fondo, converge a una imagen con regiones cerradas. Mediante componentes conectadas obtenemos dichas regiones y seleccionamos la de mayor área, siendo esta la hoja principal.

4) *Optimización de la máscara de hoja principal:* En esta etapa se rellenan huecos y bordes espurios mediante operaciones lógicas entre la máscara obtenida en el proceso anterior y la obtenida en el proceso B.

E. Modelo de clasificación

Este modelo se basó en una segmentación de Tono y Saturación de la imagen en HSV (para evitar interferencias con el brillo o la luz) a fin de enmascarar las regiones enfermas de la hoja.

1) *Enmascarado de regiones sanas:* En esta etapa se tiene como imagen de entrada la hoja principal de la planta, por lo que mediante prueba y error, se determinan los parámetros para obtener una máscara del área sana de la hoja.

2) *Clasificador:* Con la máscara de las regiones sanas y la de la hoja principal, se realiza una resta lógica, dando como resultado las áreas afectadas por enfermedades. Luego se calcula el porcentaje de área afectada de la hoja y se clasifica en "Sana" o "Enferma". Una hoja sana no puede superar el 0.1% de área afectada, siendo este porcentaje un margen de error.

III. PRUEBA Y REALIZACIÓN

A. Base de datos

La base de datos RoCoLe contiene 1560 imágenes RGB de plantas de café con diferentes características, etiquetadas en sanas y enfermas. Las imágenes fueron tomadas en diferentes momentos del día, con luz natural y de diferentes ángulos, pero siempre con la hoja principal en el centro de la imagen. Las mismas también cuentan con una segmentación manual de la hoja principal que fueron utilizadas como ground truth.

Para entrenamiento, se seleccionaron hojas tanto sanas como enfermas. En la etapa de segmentación se operó con 6 imágenes elegidas al azar, 4 de ellas etiquetadas como sanas y 2 enfermas. Mientras que en el proceso de clasificación se operó con 9 imágenes de entrenamiento, 3 sanas y 6 enfermas, con una segmentación de la hoja principal óptima. En la etapa de test para la segmentación se operó con 16 imágenes con su correspondiente ground truth entre sanas y enfermas, con una relación 3 a 1 respectivamente.

Para la clasificación se utilizaron 30 imágenes etiquetadas de ambas clases en forma balanceada.

B. Variación de los parámetros y métodos

El modelo completo se probó con el pre procesamiento de eliminación de suelo (proceso B) y sin él, teniendo diferentes resultados cualitativos y cuantitativos dependiendo la complejidad de la imagen de entrada.

Se utilizaron dos métodos distintos para la detección de bordes, dando como resultado final una mejor segmentación en el operador Laplaciano.

Todos los parámetros en este trabajo fueron obtenidos mediante prueba y error con pruebas cualitativas y cuantitativas de las imágenes resultantes.

IV. RESULTADOS

Para evaluar el desempeño en el modelo de segmentación se utilizó el método de *Intersection over Union* (IoU) utilizando la segmentación manual de la base de datos como ground truth. Además se realizó el desempeño del modelo teniendo seleccionando el método mas eficiente relativo a cada imagen (con o sin Proceso B). Los resultados obtenidos fueron los siguientes:

Segmentation							
Cant de imagenes	Desempeño c/pre Procesamiento de suelo				Desempeño s/pre Procesamiento de suelo		
	Media	Varianza	Mediana		Media	Varianza	Mediana
Entrenamiento	5	0,59	0,04	0,478	0,557	0,07	0,523
Prueba	16	0,566	0,05	0,56	0,557	0,08	0,549

Fig.4 Comparación de desempeño para segmentación

Segmentation			
Cant de imagenes	Desempeño método óptimo		
	Media	Varianza	Mediana
Entrenamiento	5	0,684	0,05
Prueba	16	0,67	0,055

Fig.5 Desempeño con el método óptimo relativo a cada imagen

Desempeño de detección de bordes, resultado final entre Canny y Laplaciano:



Fig.6 Comparación resultados finales operador Canny y operador Laplaciano respectivamente

En cuanto al desempeño de la clasificación se tuvieron en cuenta imágenes bien segmentadas en las cuales se varió el método de pre-procesamiento de suelo (con y sin él) en todas las imágenes, y luego se evaluó el desempeño del clasificador, con el método óptimo para segmentar cada tipo de imagen. Para esto se tomó como medida de desempeño el *accuracy*, los resultados fueron los siguientes:

Clasificación			
Cant de imagenes	Desempeño c/pre Procesamiento de suelo		Desempeño s/pre Procesamiento de suelo
	Accuracy		Accuracy
Entrenamiento	10	1	0,7
Prueba	17	0,47	0,667

Fig.7 Desempeño del clasificador según el método

Clasificación			
Cant de imagenes	Desempeño sobre el metodo Con mejor segmentacion		
	Accuracy		
Entrenamiento	10	1	
Prueba	17	0,705	

Fig.8 Desempeño del clasificador con método óptimo

V. CONCLUSIONES Y AVANCES FUTUROS

Se logró un método de segmentación automática para la hoja principal en fotografías de plantas de café tomadas en su contexto natural, en el cual los procesos de detección de bordes en objetos (hojas) similares superpuestos tuvo buenos resultados.

Se observó que en algunos casos, un pre-procesamiento de eliminación del suelo incurrió en una detección de bordes incorrectos, generando errores sobre la región de interés, es decir, el área donde se encuentra la hoja principal.

En general, se obtuvieron muy buenos resultados en cuanto a la identificación de la hoja principal, pero dada la complejidad del fondo, aislarla completamente requiere de mayor eficiencia en cuanto al ajuste de parámetros para acotar la región de interés, evitar bordes espurios y superposición con hojas muy próximas en profundidad.

Dado el contexto de las fotografías, se tuvo en cuenta diversos escenarios para lograr una adecuada parametrización a fin de darle robustez al método. En casos donde la segmentación no es óptima, se incurrió en errores de clasificación sobre plantas sanas, no así en plantas enfermas.

Como trabajo a futuro, en cuanto a la segmentación de la hoja principal, se podría automatizar la detección de parámetros, junto con un árbol de decisión entre fondos

complejos y simples para la pre eliminación de suelo. Además en cuanto a la clasificación se podría incursionar en inteligencia computacional con un MLP. Por otro lado, siguiendo esta línea, se podría avanzar con métodos de redes neuronales profundas.

También podría utilizarse como un modelo en otras como cítricos y tomates, las cuales comparten ciertas características en las enfermedades.

VI. AGRADECIMIENTOS

El autor de este documento quiere agradecer a Leandro Bugnon, Esteban Warinet y a toda la cátedra de Procesamiento Digital de Imágenes de la Facultad de Ingeniería y Cs. Hídricas de la Universidad Nacional del Litoral por la asistencia en el desarrollo del trabajo.

REFERENCES

- [1] International Coffee Organization. *Producción de café por continentes*. www.ico.org, 2016.
- [2] Cusme K. Llor A. Santander E. Parraga-Alava J. *RoCoLe: A robusta coffee leaf images dataset for evaluation of machine learning based methods in plant diseases recognition*. Data in brief, 2019.
- [3] Debnath R. Khan R. *SEGMENTATION OF SINGLE AND OVERLAPPING LEAVES BY EXTRACTING APPROPRIATE CONTOURS*. Computer Science and Engineering Discipline, Khulna University, Khulna, Bangladesh.
- [4] Oliveira M. M. Gastal E. S. *Domain transform for edge-aware image and video processing*. ACM SIGGRAPH 2011 papers (pp. 1-12), 2011.